ald

Sejam bem-vindos!



Utilize a nossa redes de wi-fi:

#ALDEIA

utilizando a senha

REALIZADORES

A Aldeia é muito mais que espaço

Somos um movimento de desenvolvimento de realizadores.

Temos tudo que realizadores precisam para fazer uma ideia dar certo.

http://aldeia.cc

Cursos

Confrarias

Coworking

Offices

Networking

Eventos

Acelerações



Não passe perrengue

Tem água e café à vontade, e um doce e um salgado para você pegar na hora que quiser.

Temos banheiros nos dois andares da **Cândido**:

- Primeiro andar: atrás da recepção
- Segundo andar: ao lado da escada

E atrás da recepção na unidade **Estação**.

Se algo não estiver certo, fale com a nossa equipe

Faça parte da nossa Tribo

Receba os **materiais do curso** e seu **certificado** de participação por meio da nossa comunidade virtual.

Acesse https://aldeia.cc/chamado e faça sua solicitação para fazer parte da plataforma, utilizando o e-mail da compra do curso para se identificar.



Tire uma foto deste QR code e vá direto para a página da Tribo



Pauta



1 – Apresentação Alunos

2 – Professores

3 – Agenda



Apresentação Alunos



1 – Apresentação Alunos

2 – Professores

3 – Agenda



Apresentação Alunos



Galera, queremos conhecer vocês!!



Nome



Área de atuação



O que é Data Science pra vocês?



Expectativa com o curso



Professores



1 – Apresentação Alunos

2 – Professores

3 – Agenda



Professores





Charles Adriano dos Santos

Bacharel em Análise de Sistemas - PUCPR Especialista em Engenharia de Software - PUCPR Especializando em Data Science & Big Data - UFPR

Rafael Roberto Dias

Bacharel em Estatística - UFPR Especialista em Data Science & Big Data - UFPR



Agenda



1 – Apresentação Alunos

2 – Professores

3 – Agenda







Horário Assunto

11:45

09:30	Apresentação e Anseios dos Futuros(as) Cientistas de Dados
10:00	Apresentação Equipe
10:15	Agenda do Curso
10:30	Estrutura do Curso e Objetivos
10:45	O que é Data Science and Analytics
11:00	Profissão e Carreira e Mercado Atual
11:15	Mercado Atual e Projeção
11:30	O Trabalho do Cientista de Dados

Matriz de Habilidades do Cientista de Dados







Horário Assunto

13:30	O Desafio da AgroXP Brazil
14:00	Conceitos Estatísticos Aplicados a Ciência de Dados
15:30	Conceitos Computacionais Aplicados a Ciência de Dados
16:45	Estudo de Caso – Madeira Madeira
17:15	Desafio Pessoal > Data Set x Machine Learning
17:45	Material do Curso e VM do Cientista de Dados





O que são dados?





Topics ∨

Current edition

More v

Subscribe



The world's most valuable resource is no longer oil, but data

The data economy demands a new approach to antitrust rules



Print edition | Leaders > May 6th 2017











A NEW commodity spawns a lucrative, fast-growing industry, prompting antitrust regulators to step in to restrain those who control its flow. A

Intel CEO Says Data is the New Oil











By SUSIE GHARIB June 7, 2018

Brian Krzanich believes big data will dramatically change the world.



Qual a quantidade de dados são gerados por dia?



Qual a quantidade de dados são gerados por dia?





O que é Data Science?



Ramo da Ciência especializada em:

- Coleta
- Armazenamento
- Visualização
- Transformação
- Análise
- Modelagem de Dados

Com foco principal na obtenção de

subsídios para tomada de decisões!



✓ A Profissão de Data Scientist se faz necessária pela enorme quantidade de dados que são gerados nos dias atuais



- ✓ A Profissão de Data Scientist se faz necessária pela enorme quantidade de dados que são gerados nos dias atuais
- ✓ Apenas visualizar os dados não atende mais às necessidades das empresas e instituições, a palavra de ordem é: RECOMENDAÇÃO



- ✓ A Profissão de Data Scientist se faz necessária pela enorme quantidade de dados que são gerados nos dias atuais
- ✓ Apenas visualizar os dados não atende mais às necessidades das empresas e instituições, a palavra de ordem é: RECOMENDAÇÃO
- ✓ Este profissional é o responsável por gerar conhecimento para tomada de decisões rápidas e precisas



- ✓ A Profissão de Data Scientist se faz necessária pela enorme quantidade de dados que são gerados nos dias atuais
- ✓ Apenas visualizar os dados não atende mais às necessidades das empresas e instituições, a palavra de ordem é: RECOMENDAÇÃO
- ✓ Este profissional é o responsável por gerar conhecimento para tomada de decisões rápidas e precisas
- ✓ Inclusive, é responsável por automatizar as tomadas de decisões em tempo real (Aprendizado de Máquina & Inteligência Artificial)



- ✓ A Profissão de Data Scientist se faz necessária pela enorme quantidade de dados que são gerados nos dias atuais
- ✓ Apenas visualizar os dados não atende mais às necessidades das empresas e instituições, a palavra de ordem é: RECOMENDAÇÃO
- ✓ Este profissional é o responsável por gerar conhecimento para tomada de decisões rápidas e precisas
- ✓ Inclusive, é responsável por automatizar as tomadas de decisões em tempo real (Aprendizado de Máquina & Inteligência Artificial)
- ✓ **Logo, são bem remunerados:** https://www.glassdoor.com.br/Sal%C3%A1rios/data-scientist-sal%C3%A1rio-SRCH_KO0,14.htm



- O mercado brasileiro acordou para o valor desta profissão graças as <u>startups</u>
- São empresas que já nascem 100% digitais,
 com o DNA perfeito para implantação de
 metodologias de ciência de dados
- Elas precisam sempre pensar em processos escaláveis que compreendem tomadas de decisão em tempo real
- E as demais? Estão correndo atrás do prejuízo!

\equiv **EXAME**

Imposto de Renda Venezuela Previdência Concur

Por que o Nubank sempre busca cientistas de dados e paga até R\$ 25 mil

O Nubank não exige background de programação para contratar. Confira o que a fintech valoriza e como funciona o trabalho

Por **Udacity**30 jun 2018, 09h00













- O mercado brasileiro acordou para o valor desta profissão graças as startups
- São empresas que já nascem 100% digitais, com o DNA perfeito para implantação de metodologias de ciência de dados
- Elas precisam sempre pensar em processos escaláveis que compreendem tomadas de decisão em tempo real
- E as demais? Estão correndo atrás do prejuízo!

\equiv EXAME

Imposto de Renda Venezuela Previdência Concu

Por que o Nubank sempre busca cientistas de dados e paga até R\$ 25 mil

O Nubank não exige background de programação para contratar. Confira o que a fintech valoriza e como funciona o trabalho













- O mercado brasileiro acordou para o valor desta profissão graças as startups
- São empresas que já nascem 100% digitais, com o DNA perfeito para implantação de metodologias de ciência de dados
- Elas precisam sempre pensar em processos escaláveis que compreendem tomadas de decisão em tempo real
- E as demais? Estão correndo atrás do prejuízo!

\equiv EXAME

Imposto de Renda Venezuela Previdência Concu

Por que o Nubank sempre busca cientistas de dados e paga até R\$ 25 mil

O Nubank não exige background de programação para contratar. Confira o que a fintech valoriza e como funciona o trabalho













- O mercado brasileiro acordou para o valor desta profissão graças as startups
- São empresas que já nascem 100% digitais, com o DNA perfeito para implantação de metodologias de ciência de dados
- Elas precisam sempre pensar em processos escaláveis que compreendem tomadas de decisão em tempo real
- E as demais? Estão correndo atrás do prejuízo!

EXAME

Imposto de Renda Venezuela Previdência Concu

Por que o Nubank sempre busca cientistas de dados e paga até R\$ 25 mil

O Nubank não exige background de programação para contratar. Confira o que a fintech valoriza e como funciona o trabalho





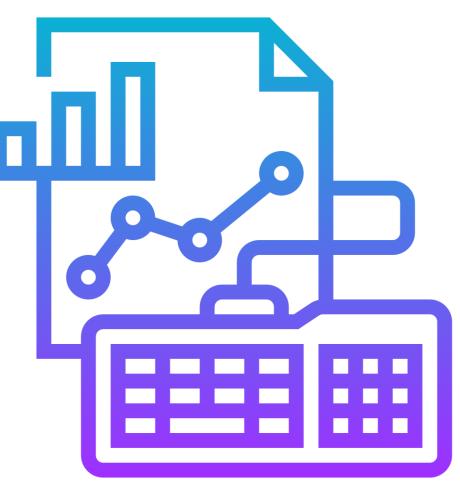






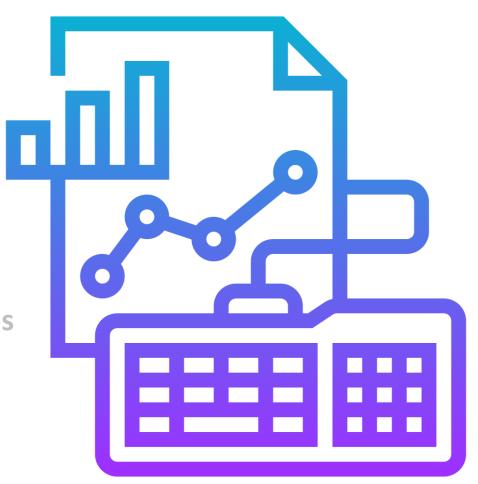


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



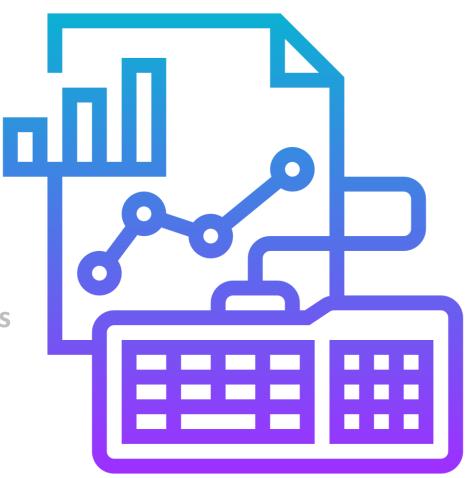


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



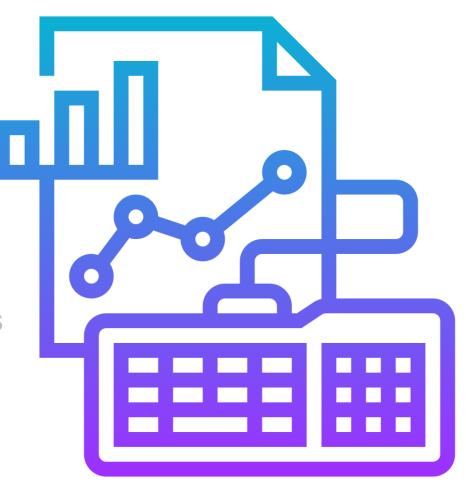


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



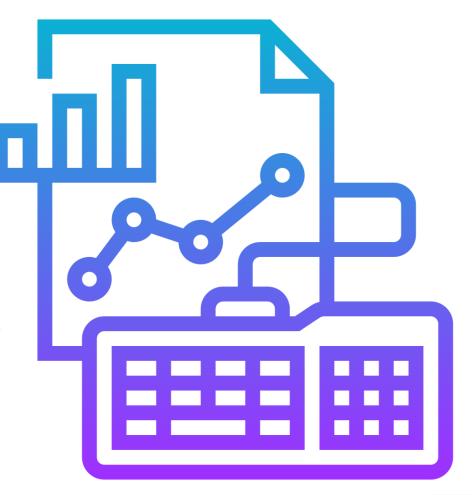


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



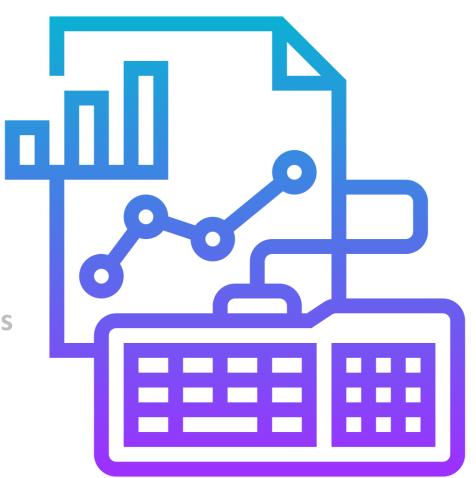


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



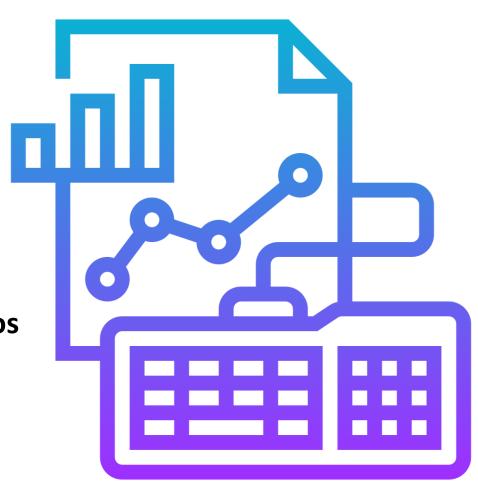


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



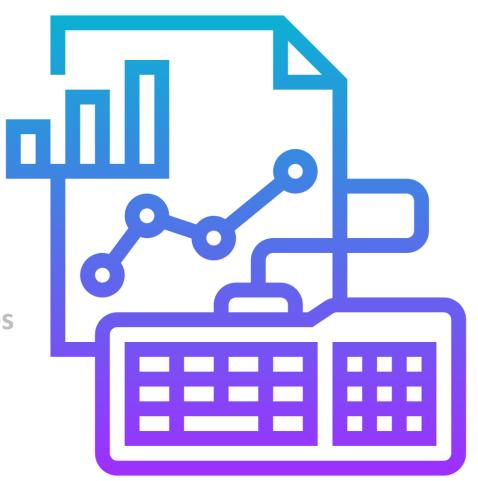


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção



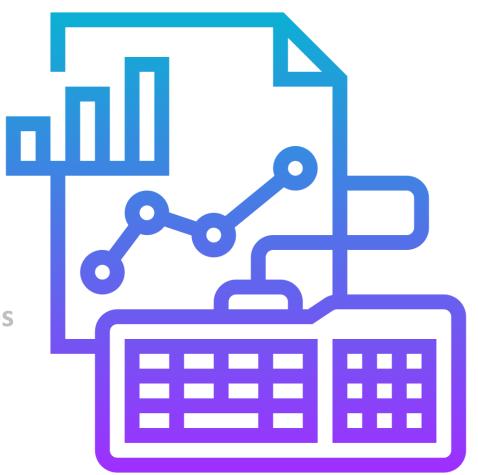


- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção





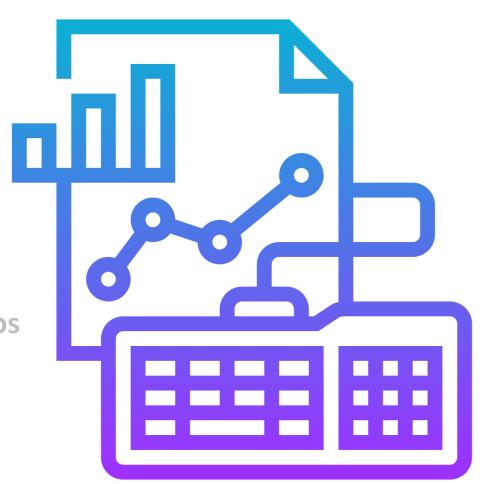
- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção





O Trabalho do Cientista de Dados

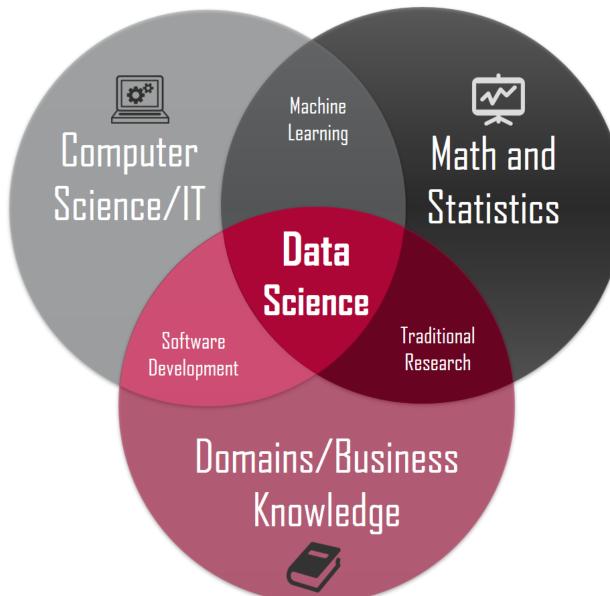
- 1. Definição do problema e levantamento de perguntas a serem respondidas
- 2. Planejamento do processo de Data Science
- 3. Coleta de dados
- 4. Processamento e limpeza dos dados
- 5. Armazenamento dos dados
- 6. Análise de dados
- 7. Construção e validação de algoritmos e modelos
- 8. Data Visualization
- 9. Disseminação da informação
- 10. Colocar modelo em produção





Habilidades







Habilidades



Habilidades	Analista de Dados	Engenheiro de Machine Learning	Engenheiro de Dados	Cientista de Dados
Ferramentas de programação				
Visualização de Dados				
Conhecimento do Negócio				
Estatística				
Data Wragling				
Machine Learning				
Engenharia de Software				
Análise Multivariada				





Importante



Muito Importante





Sua admissão como Cientista de Dados da empresa **AgroXP Brazil** não foi sem propósito. Esta empresa atua na exportação de alimentos (*commodites*) em geral. No primeiro desafio você recebeu a missão de montar, em três dias, um modelo para recomendar aos diretores da empresa os produtos que deverão ter foco na exportação nos próximos 12 meses.

- 1) Ministério de Desenvolvimento Indústria e Comércio --> apresenta os dados de TODOS commodities exportados no País desde 1997 até 1 mês atrás (formato .csv)
- 2) Tabelas auxiliares de nomenclatura de produtos com NCM Nomenclatura Comum do Mercosul (formato .xls)
- 3) Taxa cambial mensal desde 1997 (formato .csv)
- 4) Base de contratos com rentabilidade obtida pela empresa em cada produto negociado nos últimos 6 anos





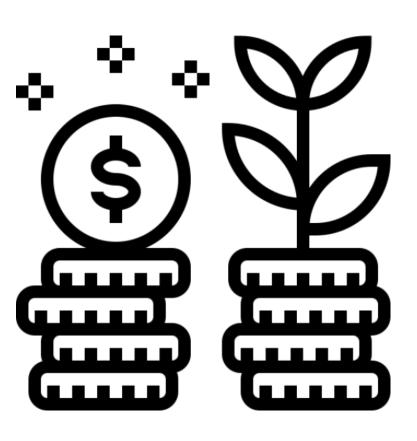


Sua admissão como Cientista de Dados da empresa **AgroXP Brazil** não foi sem propósito. Esta empresa atua na exportação de alimentos (*commodites*) em geral. No primeiro desafio você recebeu a missão de montar, em três dias, um modelo para recomendar aos diretores da empresa os produtos que deverão ter foco na exportação nos próximos 12 meses.

- 1) <u>Ministério de Desenvolvimento Indústria e Comércio</u> --> apresenta os dados de TODOS commodities exportados no País desde 1997 até 1 mês atrás (formato .csv)
- 2) Tabelas auxiliares de nomenclatura de produtos com NCM Nomenclatura Comum do Mercosul (formato .xls)
- 3) Taxa cambial mensal desde 1997 (formato .csv)
- 4) Base de contratos com rentabilidade obtida pela empresa em cada produto negociado nos últimos 6 anos







Sua admissão como Cientista de Dados da empresa **AgroXP Brazil** não foi sem propósito. Esta empresa atua na exportação de alimentos (*commodites*) em geral. No primeiro desafio você recebeu a missão de montar, em três dias, um modelo para recomendar aos diretores da empresa os produtos que deverão ter foco na exportação nos próximos 12 meses.

- 1) <u>Ministério de Desenvolvimento Indústria e Comércio</u> ---> apresenta os dados de TODOS commodities exportados no País desde 1997 até 1 mês atrás (formato .csv)
- 2) Tabelas auxiliares de nomenclatura de produtos com NCM Nomenclatura Comum do Mercosul (formato .xls)
- 3) Taxa cambial mensal desde 1997 (formato .csv)
- 4) Base de contratos com rentabilidade obtida pela empresa em cada produto negociado nos últimos 6 anos







Sua admissão como Cientista de Dados da empresa **AgroXP Brazil** não foi sem propósito. Esta empresa atua na exportação de alimentos (*commodites*) em geral. No primeiro desafio você recebeu a missão de montar, em três dias, um modelo para recomendar aos diretores da empresa os produtos que deverão ter foco na exportação nos próximos 12 meses.

- 1) <u>Ministério de Desenvolvimento Indústria e Comércio</u> ---> apresenta os dados de TODOS commodities exportados no País desde 1997 até 1 mês atrás (formato .csv)
- 2) Tabelas auxiliares de nomenclatura de produtos com NCM Nomenclatura Comum do Mercosul (formato .xls)
- 3) Taxa cambial mensal desde 1997 (formato .csv)
- 4) Base de contratos com rentabilidade obtida pela empresa em cada produto negociado nos últimos 6 anos







Sua admissão como Cientista de Dados da empresa **AgroXP Brazil** não foi sem propósito. Esta empresa atua na exportação de alimentos (*commodites*) em geral. No primeiro desafio você recebeu a missão de montar, em três dias, um modelo para recomendar aos diretores da empresa os produtos que deverão ter foco na exportação nos próximos 12 meses.

- 1) <u>Ministério de Desenvolvimento Indústria e Comércio</u> ---> apresenta os dados de TODOS commodities exportados no País desde 1997 até 1 mês atrás (formato .csv)
- 2) Tabelas auxiliares de nomenclatura de produtos com NCM Nomenclatura Comum do Mercosul (formato .xls)
- 3) Taxa cambial mensal desde 1997 (formato .csv)
- 4) Base de contratos com rentabilidade obtida pela empresa em cada produto negociado nos últimos 6 anos



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 - Variância e Desvio Padrão

7 – Previsão

8 – Correlação



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

8 – Correlação





A Média é um cálculo relativamente simples que possui muitas aplicações:

$$M\'{e}dia = rac{Soma~dos~Termos}{Quantidade~dos~Termos}$$

Na estatística a média é chamada de Esperança, comumente utilizado em Inferências e Previsões



Média



A tabela abaixo informa a cotação do dólar (moeda estrangeira) durante a última semana:

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$3,79	R\$3,78	R\$3,76	R\$3,80	R\$3,90	R\$3,95	R\$3,86	R\$3,95





A tabela abaixo informa a cotação do dólar (moeda estrangeira) durante a última semana:

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$3,79	R\$3,78	R\$3,76	R\$3,80	R\$3,90	R\$3,95	R\$3,86	R\$3,95

Bora Calcular???



Média



A tabela abaixo informa a cotação do dólar (moeda estrangeira) durante a última semana:

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$3,79	R\$3,78	R\$3,76	R\$3,80	R\$3,90	R\$3,95	R\$3,86	R\$3,95

$$M\acute{e}dia = \frac{R\$3,79 + R\$3,78 + R\$3,76 + R\$3,80 + R\$3,90 + R\$3,95 + R\$3,86 + R\$3,95}{8}$$

$$M\acute{e}dia = \frac{R\$30,79}{8}$$



Média = R\$3,85



Média



E se os valores da cotação fossem os abaixo, a média continua sendo um bom estimador?

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$1,79	R\$3,78	R\$3,76	R\$3,80	R\$15,90	R\$3,95	R\$3,86	R\$3,95

$$M\acute{e}dia = \frac{R\$1,79 + R\$3,78 + R\$3,76 + R\$3,80 + R\$15,90 + R\$3,95 + R\$3,86 + R\$3,95}{8}$$

$$M\acute{e}dia = \frac{R\$40,79}{8}$$



Média = R\$5,10



Mediana



Para o segundo exemplo é indicado utilizar a mediana, como é possível verificar abaixo:

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$1,79	R\$3,78	R\$3,76	R\$3,80	R\$15,90	R\$3,95	R\$3,86	R\$3,95

1º Passo: Organizar os números em ordem crescente:

R\$ 1.79	R\$ 3,76	R\$ 3.78	R\$ 3.80	R\$ 3.86	R\$ 3.95	R\$ 3.95	R\$ 15.90
	114 0,70						7



Mediana



2º Passo: Calcular a média dos dois números do meio:



Moda



A Moda é o valor que mais aparece num conjunto de dados

18/03	19/03	20/03	21/03	22/03	25/03	26/03	27/03
R\$3,79	R\$3,78	R\$3,76	R\$3,80	R\$3,90	R\$3,95	R\$3,86	R\$3,95



Moda



A Moda é o valor que mais aparece num conjunto de dados

							27/03
R\$3,79	R\$3,78	R\$3,76	R\$3,80	R\$3,90	R\$3,95	R\$3,86	R\$3,95

Moda = R\$3,95



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

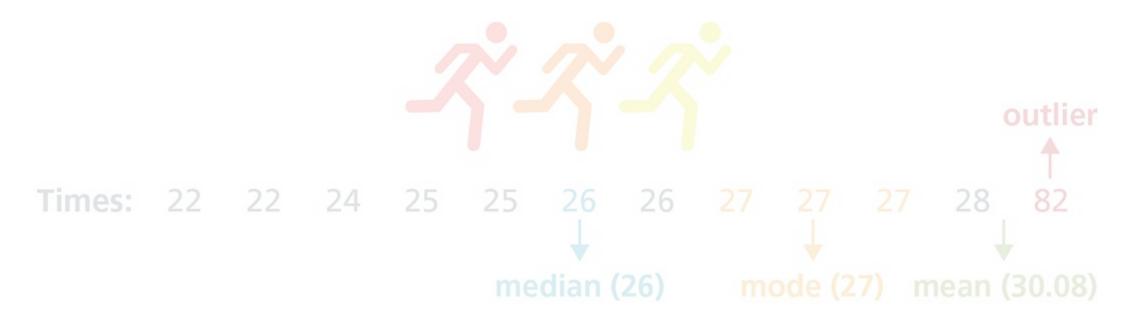
8 – Correlação



Outlier



 Em estatística, outlier, valor aberrante ou atípico, é uma observação que apresenta um afastamento das demais da série, ou que é inconsistente



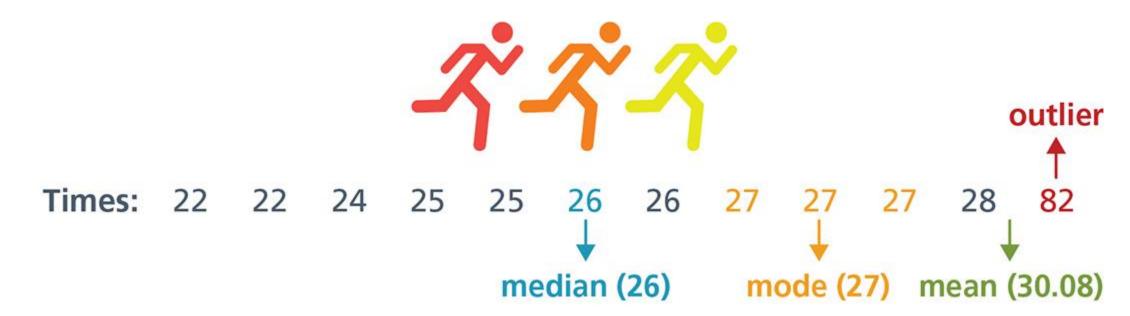
 A existência de outliers implica, tipicamente, em prejuízos a interpretação dos resultados dos testes estatísticos aplicados às amostras



Outlier



 Em estatística, outlier, valor aberrante ou atípico, é uma observação que apresenta um afastamento das demais da série, ou que é inconsistente



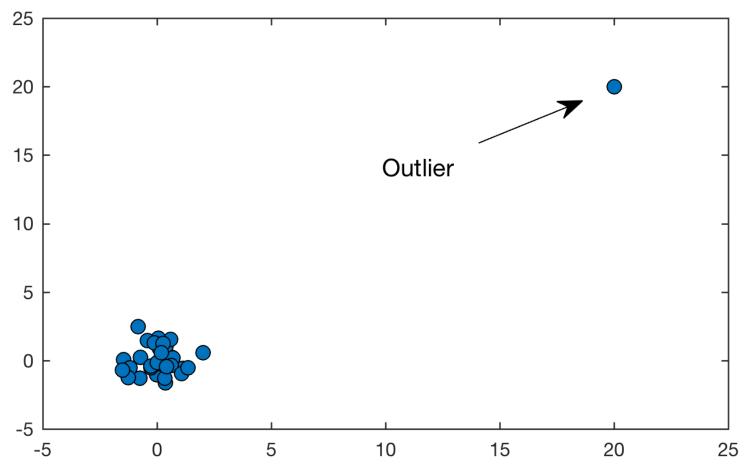
 A existência de outliers implica, <u>tipicamente</u>, em prejuízos a interpretação dos resultados dos testes estatísticos aplicados às amostras... **Depende!!!**



Outlier

1200 601700 -

 Em muitos casos encontrar o outlier é o objetivo do estudo, como por exemplo: detecção de fraudes, encontrar espécies mais resistentes, seleção de atletas de auto desempenho, etc





Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

8 – Correlação



População e Amostra

A **População** é um conjunto de pessoas, itens ou eventos sobre os quais existe interesse em inferir

A Amostra é um subconjunto de pessoas, itens ou eventos de uma população que é coletada e analisada para fazer inferências





População e Amostra

1010 do 1700 1

Métodos de Amostragem Probabilística são os que selecionam os indivíduos da população de forma que todos tenham as mesmas chances de participar da amostra.

Erro Amostral é a diferença entre um resultado amostral e o verdadeiro resultado populacional; tais erros resultam de flutuações amostrais aleatórias





População e Amostra



A fórmula para cálculo do tamanho da amostra para uma estimativa confiável da **Média Populacional (μ)** é dada por:

$$n=\frac{N}{1+Ne^2}$$

n = Número de indivíduos na amostra

N = Tamanho da População

e = Margem de Erro





Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

8 – Correlação



A palavra **probabilidade** deriva do Latim probare (provar ou testar).

Informalmente, provável é uma das muitas palavras utilizadas para eventos incertos ou desconhecidos, sendo também substituída por algumas palavras como "sorte", "risco", "azar", "chance", "incerteza", "duvidoso", dependendo do contexto.





No lançamento de um dado, observa-se os seguintes eventos e suas probabilidades:

A = Obter um número par:

$$A = \{2, 4, 6\} e n(A) = 3$$

$$P(A) = 3/6 = 0.5 \text{ ou } 50\%$$

B = Sair um número primo:

$$B = \{2, 3, 5\} e n(B) = 3$$

$$P(B) = 3/6 = 0.5 \text{ ou } 50\%$$

C = Sair um número maior ou igual a 5:

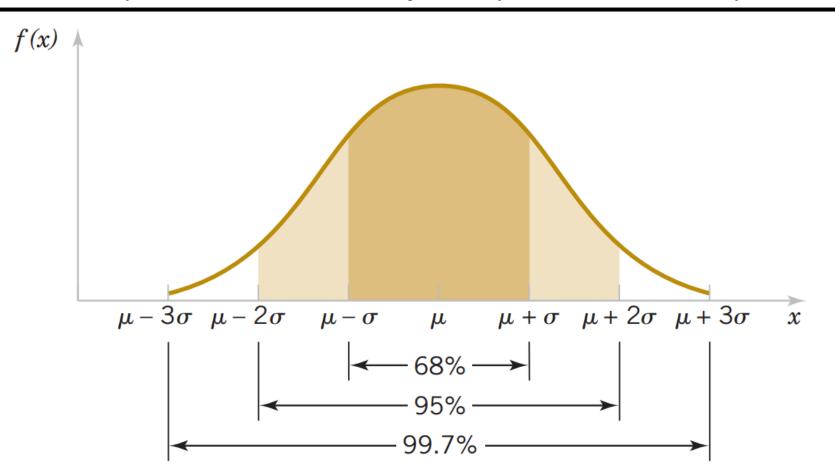
$$C = \{5, 6\} e n(C) = 2$$

D = Sair um número natural:

$$D = \{1, 2, 3, 4, 5, 6\} e n(D) = 6$$



A **Distribuição Normal** é uma das distribuições de probabilidade mais utilizadas para modelar fenômenos naturais. Isso se deve ao fato de que um grande número de fenômenos naturais apresenta sua distribuição de probabilidade tão proximamente normal







A Distribuição Normal é uma das distribuições de probabilidade mais utilizadas para modelar fenômenos naturais. Isso se deve ao fato de que um grande número de fenômenos naturais apresenta sua distribuição de probabilidade tão proximamente normal

$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 - Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

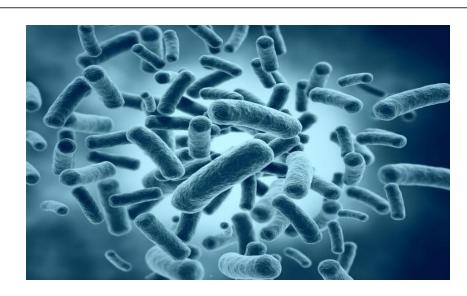
8 – Correlação



Variáveis: Discreta, Contínua

Discretas: características mensuráveis que podem assumir apenas um número inteiro finito ou infinito contável de valores e geralmente são o resultado de contagens. Exemplos: número de filhos, número de bactérias, quantidade de produtos vendidos

Contínuas: características mensuráveis que assumem valores em uma escala contínua, para as quais valores fracionais fazem sentido, usualmente medidas através de algum instrumento. Exemplos: peso (balança), tempo (relógio), pressão arterial, idade.







Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

7 – Previsão

8 – Correlação



Variância e Desvio Padrão



A variância e o desvio padrão são medidas que dão uma ideia da dispersão de uma distribuição de dados



Variância e Desvio Padrão



A variância e o desvio padrão são medidas que dão uma ideia da dispersão de uma distribuição de dados

A variância irá mostrar com eficiência a distância existente entre os valores em cada conjunto, mostrando a distância em que o conjunto se encontra com referência ao valor central

$$s^{2} = \frac{\sum_{i=1}^{n} (X_{i} - \overline{X})^{2}}{n-1}$$



Variância e Desvio Padrão



A variância e o desvio padrão são medidas que dão uma ideia da dispersão de uma distribuição de dados

A variância irá mostrar com eficiência a distância existente entre os valores em cada conjunto, mostrando a distância em que o conjunto se encontra com referência ao valor central

$$s^{2} = \frac{\sum_{i=1}^{n} (X_{i} - \overline{X})^{2}}{n-1}$$

O desvio padrão serve para identificar onde existe um erro na amostragem de dados. Se existir discordância nos dados e assim pode-se substituí-los pela média aritmética do conjunto

$$s = \sqrt{\frac{\sum (x_i - \overline{x})^2}{n - 1}}$$



Variância e Desvio Padrão

10TO 2017002

A variância e o desvio padrão são medidas que dão uma ideia da dispersão de uma distribuição de dados

	NOTA	DESVIOS EM RELAÇÃO À MÉDIA	DESVIOS AO QUADRADO
Julia	9,0	3,2	10,24
Marcos	7,0	1,2	1,44
Maria	5,0	-0,8	0,64
Andreza	4,0	-1,8	3,24
Yuri	4,0	-1,8	3,24



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

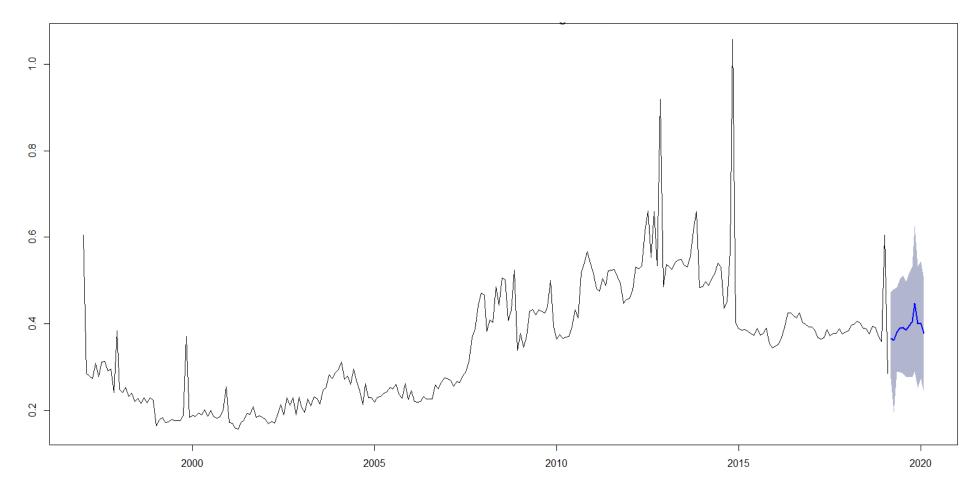
6 – Variância e Desvio Padrão

7 – Previsão

8 – Correlação



10TO 2017002



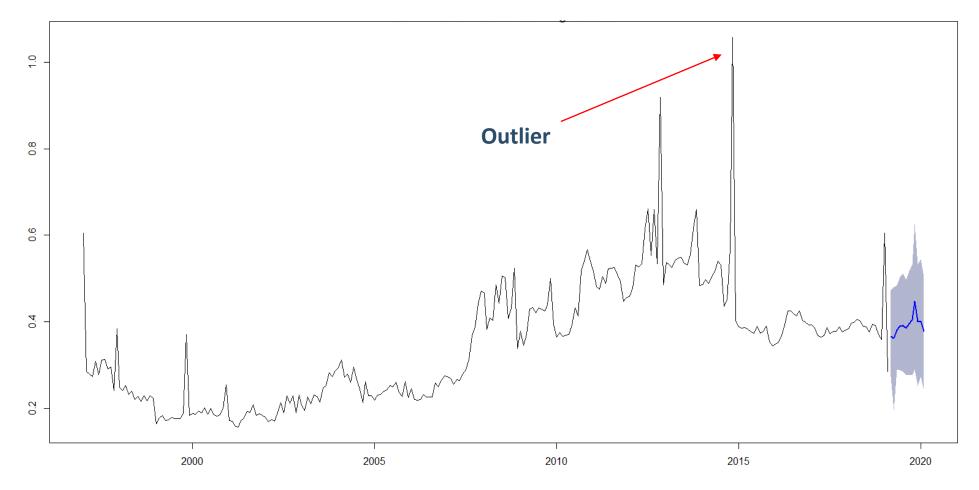


1010 do 1700 2



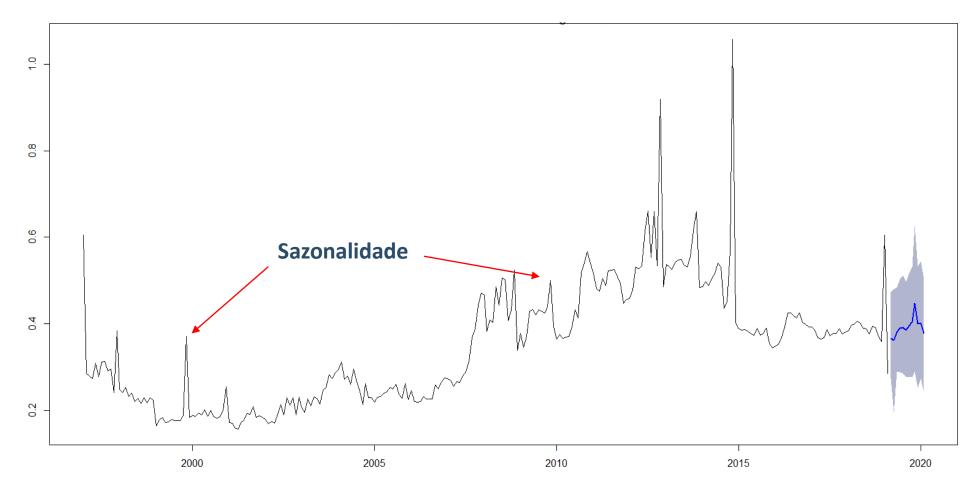


10TO 3017002



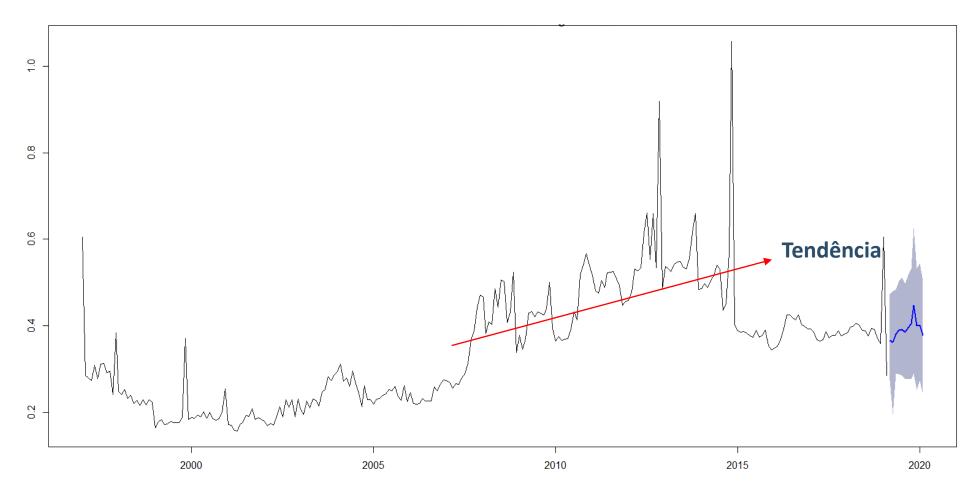


2010 do 1700 1



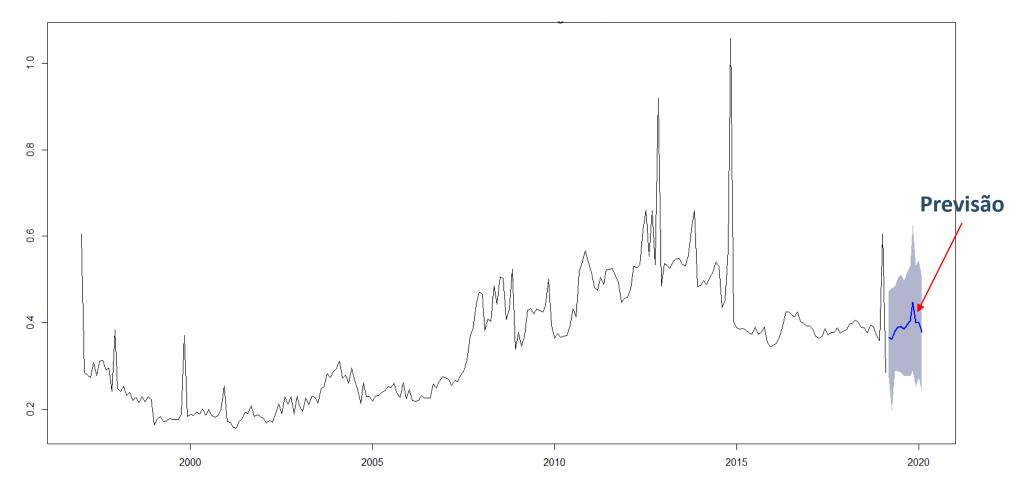


10TO 301700



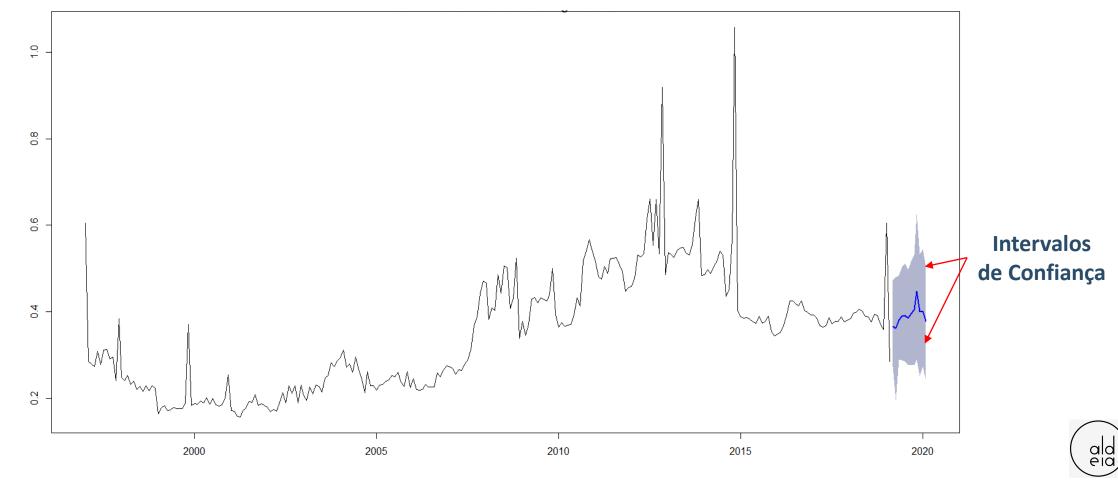


~0TO 301700,





~0TO 3017007



Conceitos Estatísticos



1 – Média, Mediana e Moda

2 – Outlier

3 – População e Amostra

4 – Probabilidade

5 – Variáveis: Discreta, Contínua

6 – Variância e Desvio Padrão

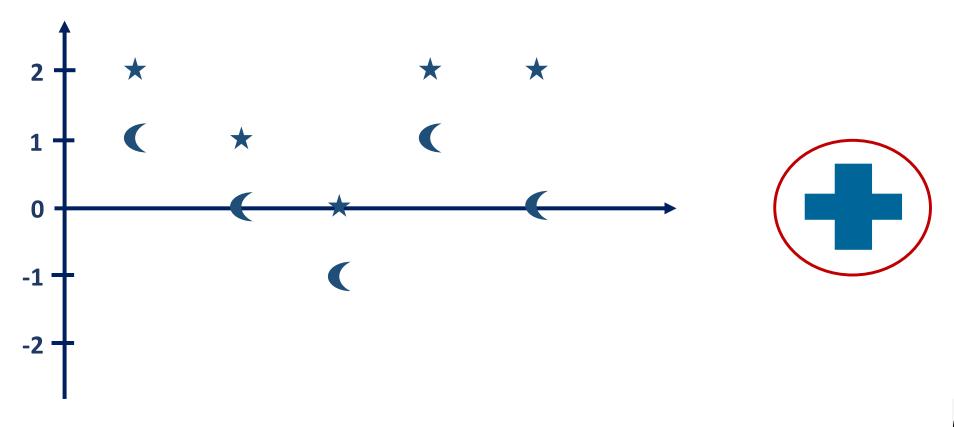
7 – Previsão

8 – Correlação



Correlação

Correlação, dependência ou associação é qualquer relação estatística (causal ou não causal) entre duas variáveis, como por exemplo, a correlação entre a céu ensolarado e poucas nuvens.

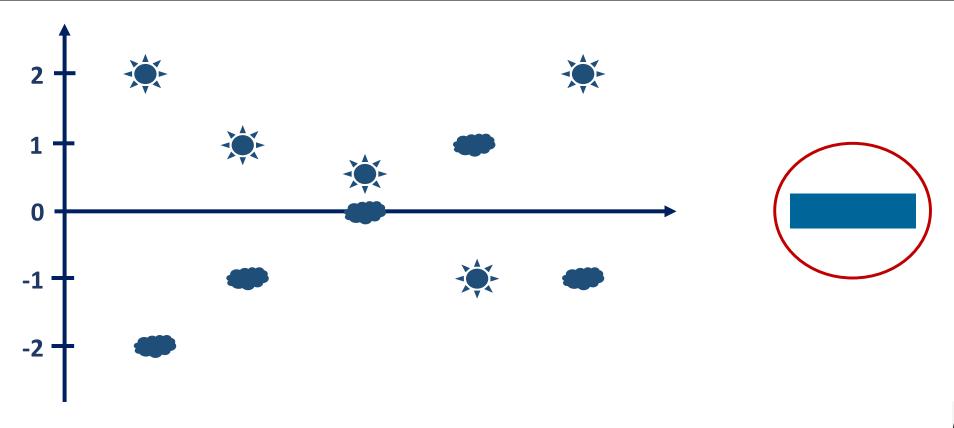




Correlação

10TO 2017001

Correlação, dependência ou associação é qualquer relação estatística (causal ou não causal) entre duas variáveis, como por exemplo, a correlação entre a estatura dos pais e a estatura dos pais e dos filhos





Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
 - **10 Machine Learning**



Ciência da Computação



1 – Objetivo

2 – Ciência da Computação

3 – Dados

4 – Sistemas Binários

5 – Lógica Booleana

6 – Conjuntos & Matrizes

7 – Banco de Dados

8 – Algoritmos

9 – Cluster e Cloud

10 – Machine Learning





Graduação área de Tecnologia da Informação → de 3 a 5 anos

Especializações em TI → de 1 a 2 anos

Nosso curso →32h





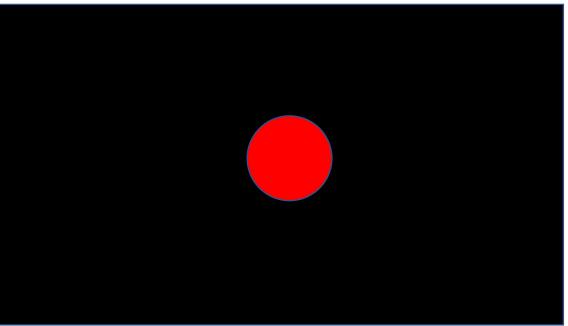


Graduação área de Tecnologia da Informação → de 3 a 5 anos

Especializações em TI \rightarrow de 1 a 2 anos

Nosso curso →32h





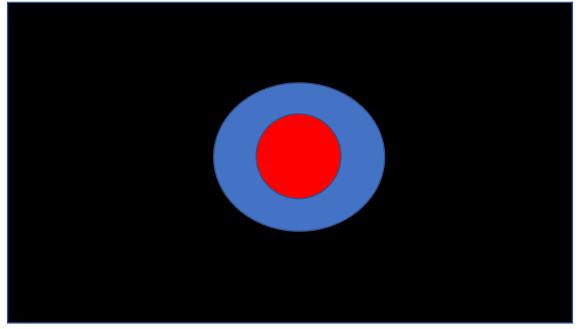


Graduação área de Tecnologia da Informação → de 3 a 5 anos

Especializações em TI \rightarrow de 1 a 2 anos

Nosso curso →32h





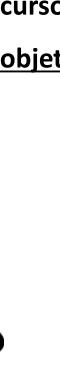


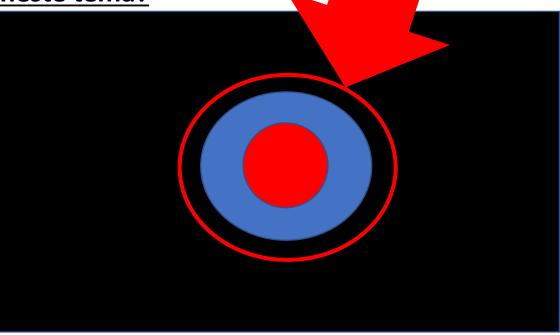


Graduação área de Tecnologia da Informação → de 3 a 5 anos

Especializações em TI \rightarrow de 1 a 2 anos

Nosso curso →32h







Ciência da Computação

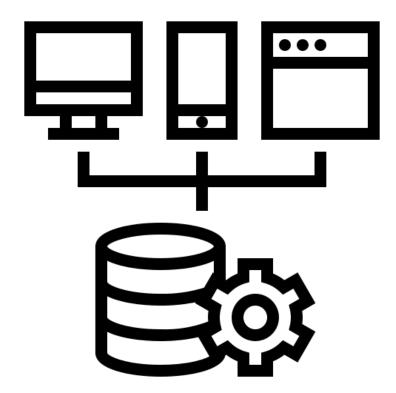


- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
 - 10 Machine Learning



Ciência da Computação

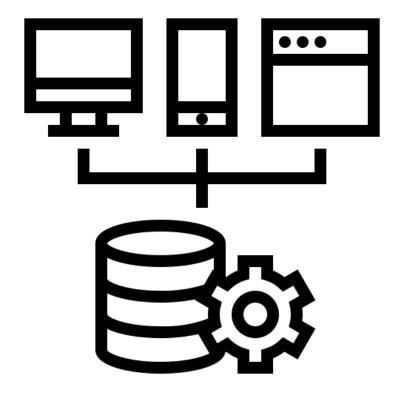




Para você, o que é a CIÊNCIA DA COMPUTAÇÃO?



Ciência da Computação - Definição



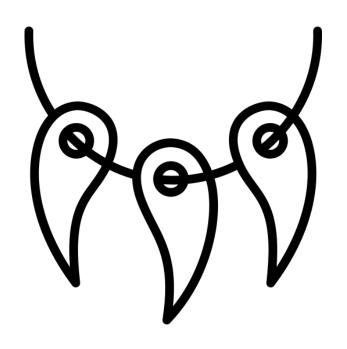
Para você, o que é a CIÊNCIA DA COMPUTAÇÃO?

Utilizar instrumentos computacionais para, com métodos, automatizar e exponenciar a resolução de problemas de processamento de dados.

Treinados para resolver problemas!



Ciência da Computação - História



Desde os primórdios até hoje em dia...

Registro de dados conforme os grupos sociais foram surgindo ("Matei 3 tigres este mês, e você?").

A história da computação acompanha o crescimento das civilizações, onde se faziam necessárias técnicas e instrumentos para operações matemáticas (como o Ábaco criado há ~5.500 anos atrás).

Mas o que é o DADO?



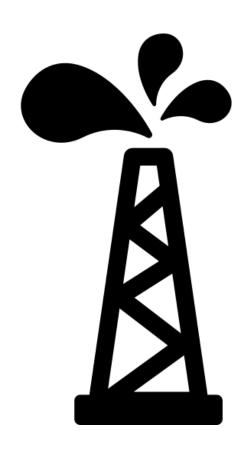
Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
 - 10 Machine Learning



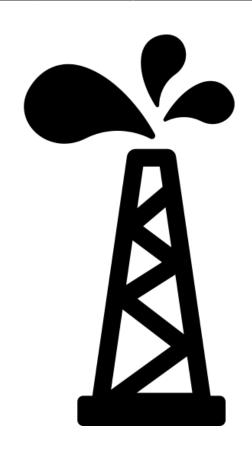
Ciência da Computação — História dos Dados



O dado (no singular) é mesmo o novo petróleo?



Ciência da Computação – História dos Dados

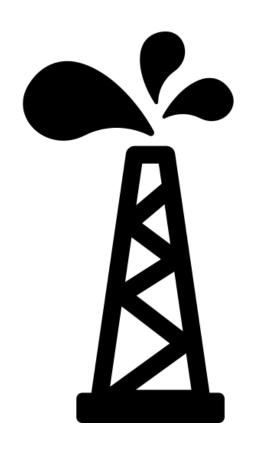


O dado (no singular) é mesmo o novo petróleo?

O dado é a matéria-prima. Sem ser "refinado" não gera valor.



Ciência da Computação – História dos Dados

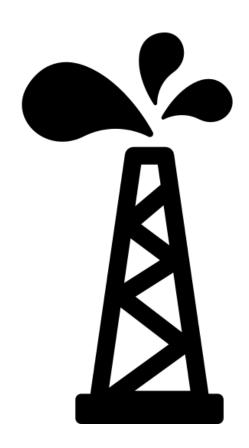


Dados refinados, trabalhados geram INFORMAÇÃO

Em computação temos estudos referente a **teoria da informação**... ela vem estudando relatos de 30mil anos atrás, do homem primitivo, buscando se comunicar, expressar de forma a ser compreendido seus pensamentos internos. Todos estes "dados" utilizados por nós buscam, de forma encadeada, transmitir uma informação a respeito de um tema.



Ciência da Computação - História dos Dados



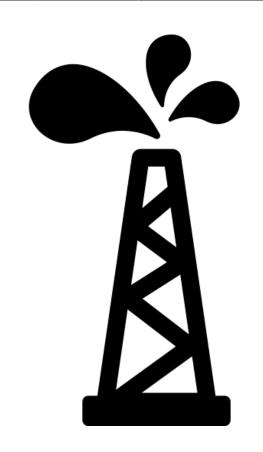
Porém a parte nobre dos Dados não é apenas se tornar informação, mas sim um conjunto de informações que gere **CONHECIMENTO**



Dados → Informação → Conhecimento



Ciência da Computação – História dos Dados



CONHECIMENTO É O NOVO ATIVO DE FATO

28/03/2019 - 15H51 - ATUALIZADA ÀS 15H51 - POR ÉPOCA NEGÓCIOS ONLINE

McDonald's investe US\$ 300 milhões para adquirir startup de IA e big data

Primeira mudança após a compra da Dynamic Yield deverá ser vista nos drive thrus da rede de fast food

Indústria 4.0 pode economizar R\$ 73 bilhões ao ano para o Brasil

Os ganhos de eficiência produtiva correspondem a uma economia de R\$ 31 bilhões

Fernando Rotta | 20/12/2017



Está chegando a era dos superhumanos. E eles são chineses

Tiago Cordeiro, especial para a Gazeta do Povo [22/03/2019] [11:09]



Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
 - 10 Machine Learning



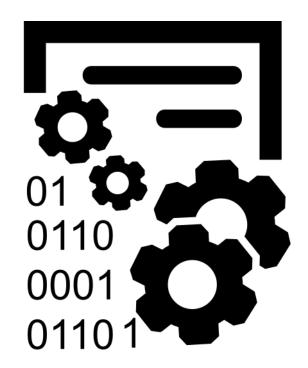
Ciência da Computação - Sistemas Binários



E como o dado é refinado em um instrumento computacional?



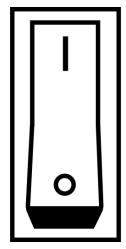
Ciência da Computação - Sistemas Binários/



E como o dado é refinado em um instrumento computacional?

On/Off

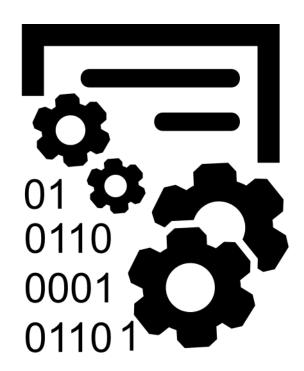
Ligado/Desligado



Ou, na notação binária ZERO ou UM



Ciência da Computação - Sistemas Binários/



Através deste sistema binário temos representação de qualquer dado. O decimal 4 por exemplo representa-se por LIGADO, Desligado, Desligado:

Número Decimal	Representação Binária	
0	0	
1	1	
2	10	
3	11	
4	100	



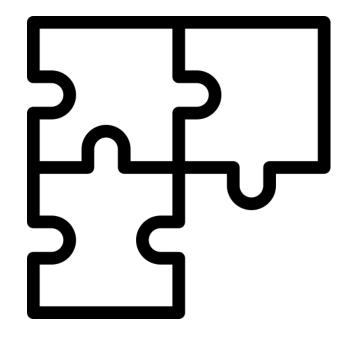
Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
- 10 Machine Learning

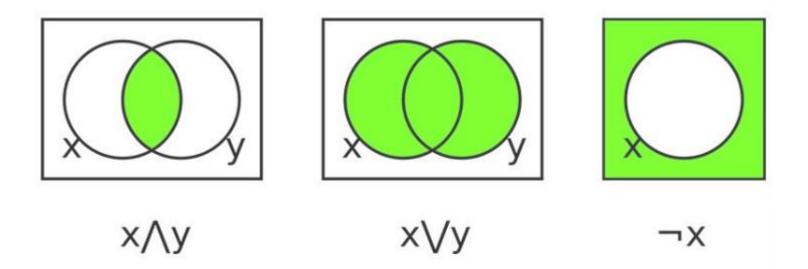


Ciência da Computação – Lógica Booleana



Criada em 1847 George Boole cria o conceito de lógica simbólica (base para sistemas computacionais)

3 operadores principais {AND, OR, NOT}





Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
- 10 Machine Learning

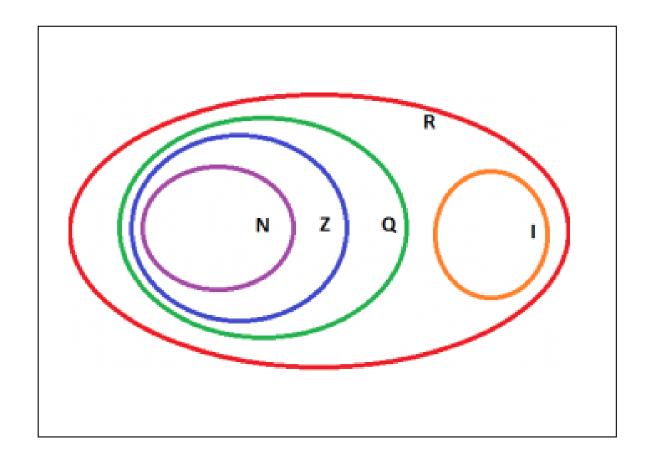


Conjuntos & Matrizes



Os Conjuntos são coleções de elementos:

- Conjuntos dos Números Naturais
- Conjunto dos Números Inteiros
- Conjunto dos Números Racionais
- Conjunto dos Números Irracionais
- Conjunto dos Números Reais



Conjunto Planetas Sistema Solar = {Mercúrio, Vênus, Terra, Marte, Júpiter, Saturno, Urano}

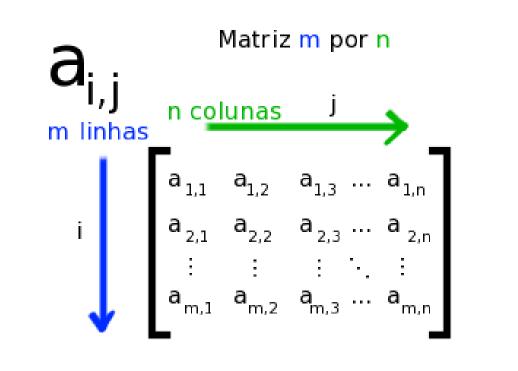


Conjuntos & Matrizes



Matrizes são Valores apresentados em forma tabelas com linhas e/ou colunas:

- Representações de Matrizes
- Operações de Matrizes
- Matriz Inversa
- Sistemas de Equações Resolução por Matrizes





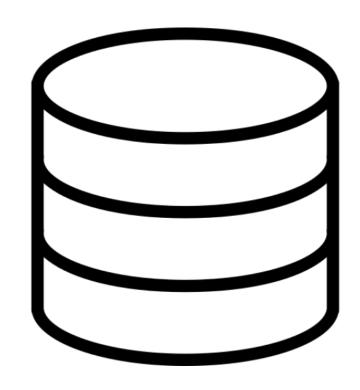
Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
- 10 Machine Learning



Ciência da Computação – Banco de Dados



E tudo junto agora (teoria de conjuntos, sistemas booleanos, matrizes, teoria da informação)

Vossa Majestade o Banco de Dados

Armazenar dados estruturados e não estruturados (conforme o SGDB, Sistemas Gerenciador de Banco de Dados)

Veremos a frente no curso, em mais detalhes, o nosso BD (para os íntimos) utilizando o SGBD PostgreSQL



Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud
 - 10 Machine Learning



Ciência da Computação – Algoritmos



A esposa do programador disse:

- Vá ao mercado e traga um litro de leite. Se tiver ovos, traga seis.

O programador voltou com seis litros de leite, então sua esposa disse:

- Programador! Porquê você trouxe seis litros de leite?
 E o Programador respondeu:
- Eles tinham ovos...



Ciência da Computação – Algoritmos



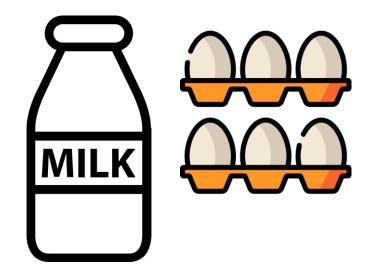
E um conjunto sequencial de passos para resolução de um problema. Utiliza os operados lógico booleanos e estrutura condicionais e de repetição.

Exemplo de algoritmo (ida do programador ao mercado):

```
Vá ao Mercado
TemOvos <- Verdadeiro
Leite <- 1
Ovos <- 1
Cesta <- []
Cesta <- Leite
SE TemOvos Então
Cesta <- Leite*6
```



Ciência da Computação – Algoritmos



Exemplo de algoritmo – Agora com pedido correto:

```
Vá ao Mercado
TemOvos <- Verdadeiro
Leite <- 1
Ovos <- 1
Cesta <- []
Cesta <- Leite
SE TemOvos Então
  Para Contador De 1 até 6 Faça
    Cesta <- Cesta + Ovos
```



Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud

10 – Machine Learning



Ciência da Computação – Cluster e Cloud

Computação em Nuvem é a distribuição de serviços de computação – servidores, armazenamento, bancos de dados, redes, software, análises, inteligência e muito mais pela Internet ("a nuvem"), proporcionando inovações mais rápidas, recursos flexíveis e economia na escala





Ciência da Computação



- 1 Objetivo
- 2 Ciência da Computação
 - 3 Dados
 - 4 Sistemas Binários
 - 5 Lógica Booleana
- 6 Conjuntos & Matrizes
 - 7 Banco de Dados
 - 8 Algoritmos
 - 9 Cluster e Cloud

10 – Machine Learning



2010 do 1200 2

Machine Learning: ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência

Supervisionado

Regressão: Prever os resultados ou tentativa de mapeamento de variáveis para função contínua

Classificação: Prever os resultados ou tentativa de mapeamento de variáveis de entrada em categorias distintas

Não Supervisionado

Permite abordar problemas com pouca ou nenhuma ideia dos resultados
Esta abordagem é utilizada para agrupar os dados com base em relações entre eles, ou para detectar tendências.
O desafio aqui é que não há feedback com base nos resultados da previsão

Reforço

Maximizar o resultado baseado em um recompensa.

*Fonte: https://medium.com/opensanca/aprendizagem-de-maquina-supervisionada-ou-n%C3%A3o-supervisionada-7d01178cd80a



Machine Learning: ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência

Supervisionado

Regressão: Prever os resultados ou tentativa de mapeamento de variáveis para função contínua

Classificação: Prever os resultados ou tentativa de mapeamento de variáveis de entrada em categorias distintas

Não Supervisionado

Permite abordar problemas com pouca ou nenhuma ideia dos resultados
Esta abordagem é utilizada para agrupar os dados com base em relações entre eles, ou para detectar tendências.
O desafio aqui é que não há feedback com base nos resultados da previsão

Reforço

Maximizar o resultado baseado em um recompensa.

*Fonte: https://medium.com/opensanca/aprendizagem-de-maquina-supervisionada-ou-n%C3%A3o-supervisionada-7d01178cd80a

70TO 301700;

Machine Learning: ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência

Supervisionado

Regressão: Prever os resultados ou tentativa de mapeamento de variáveis para função contínua

Classificação: Prever os resultados ou tentativa de mapeamento de variáveis de entrada em categorias distintas

Não Supervisionado

Permite abordar problemas com pouca ou nenhuma ideia dos resultados
Esta abordagem é utilizada para agrupar os dados com base em relações entre eles, ou para detectar tendências.
O desafio aqui é que não há feedback com base nos resultados da previsão

Reforço

Maximizar o resultado baseado em um recompensa.

*Fonte: https://medium.com/opensanca/aprendizagem-de-maquina-supervisionada-ou-n%C3%A3o-supervisionada-7d01f78cd80a

10TO 301700.

Machine Learning: ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência

Supervisionado

Regressão: Prever os resultados ou tentativa de mapeamento de variáveis para função contínua

Classificação: Prever os resultados ou tentativa de mapeamento de variáveis de entrada em categorias distintas

Não Supervisionado

Permite abordar problemas com pouca ou nenhuma ideia dos resultados
Esta abordagem é utilizada para agrupar os dados com base em relações entre eles, ou para detectar tendências.
O desafio aqui é que não há feedback com base nos resultados da previsão

Reforço

Maximizar o resultado baseado em um recompensa.

*Fonte: https://medium.com/opensanca/aprendizagem-de-maquina-supervisionada-ou-n%C3%A3o-supervisionada-7d01178cd80a

7010 do 1700.

Machine Learning: ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência

Supervisionado

Regressão: Prever os resultados ou tentativa de mapeamento de variáveis para função contínua

Classificação: Prever os resultados ou tentativa de mapeamento de variáveis de entrada em categorias distintas

Não Supervisionado

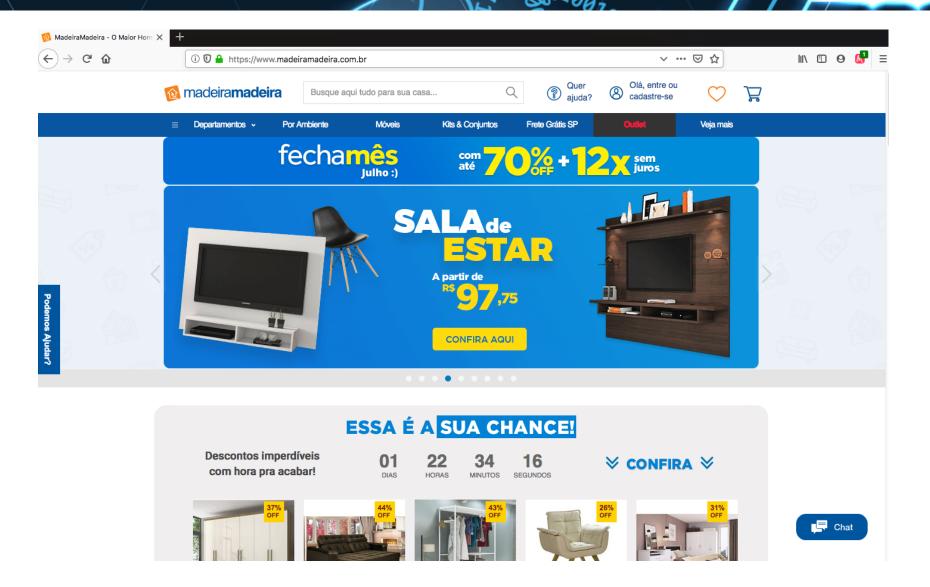
Permite abordar problemas com pouca ou nenhuma ideia dos resultados
Esta abordagem é utilizada para agrupar os dados com base em relações entre eles, ou para detectar tendências.
O desafio aqui é que não há feedback com base nos resultados da previsão

Reforço

Maximizar o resultado baseado em um recompensa.

*Fonte: https://medium.com/opensanca/aprendizagem-de-maquina-supervisionada-ou-n%C3%A3o-supervisionada-7d01f78cd80a

Estudo de Caso





Pauta



1 – Desafio Pessoal

2 – Material do Curso

3 – Virtual Machine do Cientista de Dados



Pauta



1 – Desafio Pessoal

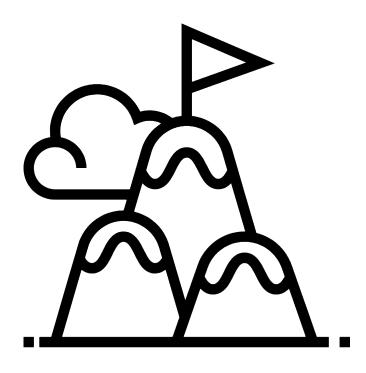
2 – Material do Curso

3 – Virtual Machine do Cientista de Dados



Desafio Pessoal





Machine Learning

Apresentação na Aldeia

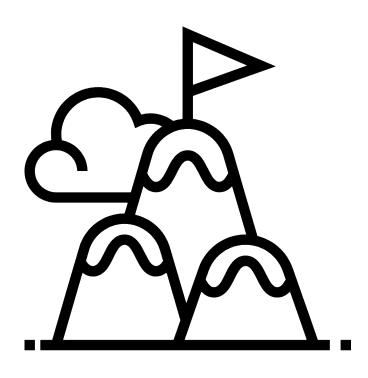
O Melhor Algoritmo Vence

- → Maior Acurácia
- → Menor Tempo Processamento



Desafio Pessoal





Machine Learning

Apresentação na Aldeia

O Melhor Algoritmo Vence

- → Maior Acurácia
- → Menor Tempo Processamento

Você vai AMARELAR no Desafio?



Desafio Pessoal





Pauta



1 – Desafio Pessoal

2 – Material do Curso

3 – Virtual Machine do Cientista de Dados



Material do Curso





Best Practice → **Versionamento**

Utilização de repositório (geralmente na cloud) para sincronizar e criar versões de arquivo.

É uma boa prática quando estamos gerando scripts / códigos fontes.

Soluções mais difundidas utilizadas:

SVN → https://subversion.apache.org/

GiT → https://git-scm.com/

Nosso repositório! → https://github.com/datasciencealdeia/201907.git

Apresentações, Scripts, Dados Utilizados e etc, sempre atualizados



Pauta



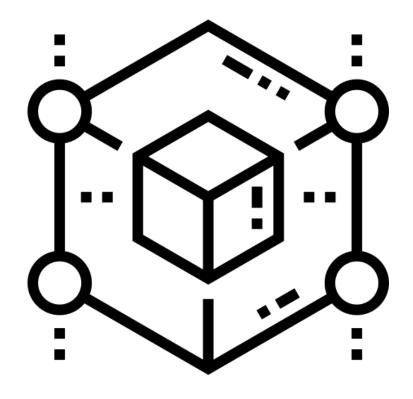
1 – Desafio Pessoal

2 – Material do Curso

3 – Virtual Machine do Cientista de Dados







Conceito da Virtualização de Ciência da Computação

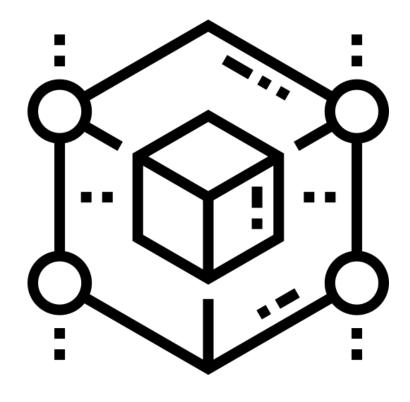
Software que simula um computador (máquina virtual) utilizando recursos do computador que está instalado (máquina host)

Pode ter configuração dimensionada com simples configuração: Memória RAM, HD, Placa de Rede e etc. (Sempre limitada a configuração física do computador host)

Utilizado na prática nas máquinas cluster/cloud





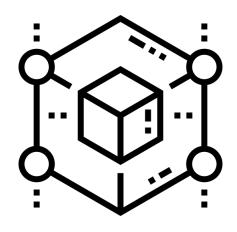


Configuração da Nossa Virtual Machine (VM)

- Sistema Operacional: Ubuntu 16.04.02 LTS 32 Bits
- 2 Gb de Memória RAM
- 50 Gb de HDD
- Softwares Embarcados:
 - ETL \rightarrow Pentaho 5.0.1
 - Banco de Dados → PostgreSQL 10.7
 - Linguagens → R e Python 3
 - IDE Versionamento → GitEye 2.2







1) Download do Virtual Box (versão 6.0.4)

https://www.virtualbox.org/wiki/Downloads

2) Download da nossa VM (~7 Gb)

https://drive.google.com/open?id=1OVr0BVaok5cfAKJ8XinzFY0dF-W RpQK

3) Executar o Virtual Box

Opção Arquivo > Importar Appliance > Escolher o arquivo baixado anteriormente para importar (DataScience.ova)

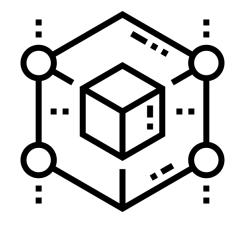
user: ds

passwd: ds2019Xpto

IMPORTANTE!!! A VM será a base para os exercícios das próximas aulas







Dúvidas?

Momento Help Desk VM





- **B** Charles Adriano dos Santos
- charles.a.santos@caelis.it
- in chadri
- **941 99144 6663**

- **B** Rafael Roberto Dias
- rafael.dias@madeiramadeira.com.br
- rafael-roberto-dias-00b39123
- **S** 41 99672 7170